

## I. Le cahier des charges

L'objectif du projet était de réaliser générateur d'analyse lexicale (Gal). Pour cela, plusieurs étapes sont nécessaires, et ont été découpées dans plusieurs fichiers :

1. lire le fichier d'entrée : `lecture.h` et `lecture.c`
2. construction de l'arbre de syntaxe abstraite : `arbre.h` et `arbre.c`
3. construction de l'automate fini non déterministe : `nfa.h` et `nfa.c`
4. construction de l'automate fini déterministe : `dfa.h` et `dfa.c`
5. construction de l'automate fini déterministe minimal : `dfa_min.h` et `dfa_min.c` TODO
6. génération du code source de l'analyseur lexicale TODO

## II. Lecture du fichier et alphabet

Le fichier `alphabet.c` contient les fonctions de gestion de l'alphabet. Le but de ces fonctions est de pouvoir assez facilement changer d'alphabet en cas de besoin.

`char next_letter(char ch)` : Renvoie la première lettre de l'alphabet si `ch = 0`, ou la lettre suivant `ch` dans l'alphabet s'il y en a une et `-1` s'il n'y en a plus.

`int letter_rank(char ch)` : Renvoie le rang de la lettre `ch` dans l'alphabet, ou `-1` si ce n'est pas une lettre de l'alphabet.

Le fichier `lecture.c` contient les fonctions de lecture et de traitement du fichier.

`void lecture(char *nom, char *exp)` : Lit le fichier `nom` contenant une expression régulière, et stocke son contenu dans `exp`. Si le contenu du fichier ne finit pas par `\n` ou qu'il contient un caractère non reconnu, affiche un message d'erreur et termine le programme.

`void add_concat(char *src, char *dest)` : Ajoute des points à la chaîne `src` aux endroits des concaténations (par exemple `ab` devient `a.b`), remplace les couples de parenthèses vides `()` par `ε` (codé par `_`) et stocke le résultat dans `dest`.

`char *get_filename(char *fullpath)` : Prend en paramètre le chemin complet vers un fichier, et renvoie le nom du fichier en enlevant le chemin et l'extension.

## III. Construction de l'arbre de syntaxe abstraite

### 1) Notation polonaise inversée

Pour construire l'arbre de syntaxe abstraite, après avoir un peu reformaté la chaîne grâce à la fonction `add_concat` décrite plus haut, j'ai choisi de passer par une écriture en notation polonaise inversée (NPI) en utilisant l'algorithme 1 (fonction `to_postfix`).

### 2) Construction de l'arbre

Ensuite, on construit l'arbre à partir de cette expression par l'algorithme 2 (fonction `to_tree`). Pour cela, un arbre (TREE) est un pointeur vers un nœud (NODE), lui-même composé d'un caractère `val` indiquant le contenu du nœud, et de deux pointeurs `left` vers `right` vers les éventuels fils gauche et droit.

Pour ces deux étapes, on utilise une pile (implémentée dans `pile.c`) soit comme pile de caractères (avec les fonctions `push_char`, `pop_char` et `sommet_char` implémentée dans `pile.c`), soit comme pile d'arbres (avec `push_tree`, `pop_tree` et `sommet_tree` de `arbre.c`).

## IV. Construction de l'automate fini non déterministe (NFA)

**Entrée :** Une chaîne de caractères *entry*

**Sortie :** Une chaîne de caractères *postfix* correspondant à la notation polonaise inversée de l'entrée

**Traitement**

Créer une pile vide

$npi \leftarrow []$

**pour chaque** *caractère ch de entry* **faire**

**si** *ch est une lettre* **alors**

    | ajouter *ch* à *postfix*

**sinon si** *ch est une parenthèse ouvrante* **alors**

    | empiler *ch*

**sinon si** *ch est une parenthèse fermante* **alors**

**tant que** *pile est non vide et que le sommet de la pile n'est pas une parenthèse ouvrante* **faire**

      | dépiler un caractère et l'ajouter à *postfix*

**si** *pile est vide* **alors**

      | quitter // Problème de parenthésage

**sinon**

      | dépiler la parenthèse ouvrante

**sinon**

**tant que** *pile est non vide et que le sommet de la pile a une priorité supérieure à ch* **faire**

      | dépiler un caractère et l'ajouter à *postfix*

    empiler *ch*

**tant que** *pile est non vide* **faire**

  | dépiler un caractère et l'ajouter à *postfix*

**si** *le caractère est une parenthèse ouvrante* **alors**

    | quitter // Problème de parenthésage

**Algorithme 1 :** Algorithme de passage en notation polonaise inversée (Shunting-yard)

**Entrées :** Une chaîne de caractères *src* en NPI

**Sortie :** L'arbre *tree* correspondant

**Traitement**

**si** *src est vide* **alors** // langage vide

    | Renvoyer un arbre vide

  Créer une pile vide

**pour chaque** *caractère ch de src* **faire**

    Créer un nœud *nd* étiqueté par *ch*

**si** *ch est une lettre* **alors**

      | *nd* est une feuille

**sinon si** *ch = '\*'* **alors** // opérateur unaire

      | dépiler le dernier arbre

      | le mettre en fils gauche de *nd*

**sinon** // opérateur binaire

      | dépiler les deux derniers arbres

      | le mettre comme fils gauche et droit de *nd*

    empiler *nd*

  dépiler dans *tree*

**si** *la pile n'est pas vide* **alors**

    | quitter // Expression mal construite

**Algorithme 2 :** Algorithme de création de l'arbre de syntaxe abstraite